边缘联邦学习中的统计异构性与激励机制：综述与折中框架

作者姓名

2026 年 6 月 22 日

摘要

边缘联邦学习 (Edge Federated Learning, EFL) 在释放分布式数据价值的同时，面临数据非独立同分布 (Non-IID) 导致的统计异构性与边缘节点参与积极性不足引发的系统异构性两大难题。本文系统综述了现有应对统计异构性的主流方法，包括个性化联邦学习、聚类分组与知识蒸馏等，并深入剖析其在资源受限边缘环境下的固有缺陷；同时梳理了激励机制设计面临的信息不对称、预算约束与可扩展性等实用困境。在此基础上，本文提出一个结合简单启发式客户端选择与轻量级数据保护的折中可行框架。最后，针对是否应放弃全局模型转向局部个性化模型的争论，本文从收敛性、泛化能力与部署成本等维度给出观点与依据。本文综述涵盖了 12 篇以上可检索的核心文献，力求为边缘联邦学习的工程实践提供理论参考。

1 引言

随着物联网 (Internet of Things, IoT) 设备的爆炸式增长，海量数据在边缘节点上生成。传统集中式机器学习需要将数据上传至云端，带来隐私泄露风险与巨大的通信开销。联邦学习 (Federated Learning, FL)[6] 作为一种分布式机器学习范式，允许客户端在本地训练模型，仅上传模型参数或梯度，从而在保护数据隐私的同时降低骨干网传输压力。然而，边缘联邦学习场景下，设备计算能力、通信带宽与电量水平参差不齐，且数据分布呈现高度非独立同分布 (Non-IID) 特征，导致全局模型收敛缓慢甚至性能退化。

本文围绕以下核心问题展开：(1) 现有应对统计异构性的方法在资源受限边缘环境下存在哪些缺陷？(2) 激励机制设计面临哪些实用困境？(3) 如何构建一个兼顾简单性与有效性的折中框架？(4) 全局模型与局部个性化模型孰优孰劣？

2 统计异构性及其应对方法

2.1 问题形式化

考虑一个由 K 个边缘客户端组成的联邦学习系统，客户端 k 拥有本地数据集 $\mathcal{D}_k$，其数据分布为 $P_k(x, y)$。在理想 IID 假设下，所有客户端共享同一数据分布 $P_k = P$。然而，在边缘现实中，P_k 之间存在显著差异。标准的联邦优化目标为：

$$\min_{w} F(w) = \sum_{k=1}^{K} \frac{n_k}{n} F_k(w), \quad F_k(w) = \frac{1}{n_k} \sum_{i \in \mathcal{D}_k} \ell(w; x_i, y_i), \tag{1}$$

其中 $n_k = |\mathcal{D}_k|$，$n = \sum_k n_k$，ℓ 为损失函数。当 P_k 差异较大时，局部目标 $F_k(w)$ 的极小点与全局目标 $F(w)$ 的极小点偏离严重，导致 FedAvg 等算法收敛至次优点或振荡 [4]。

2.2 个性化联邦学习

个性化联邦学习 (Personalized FL, PFL) 的核心思想是在全局共享表示与本地个性化头之间取得平衡。代表性工作包括：

局部个性化层。Arivazhagan 等 [1] 提出 FedPer，将深度网络划分为基础层与个性化层。全局聚合仅作用于基础层，个性化层保留在本地微调：

$$w^{(t+1)} = \begin{cases} \text{FedAvg}(\{w_k^{(t)}\}), & \text{若} l \in \text{基础层} \\ w_k^{(t)} - \eta \nabla F_k(w_k^{(t)}), & \text{若} l \in \text{个性化层} \end{cases} \tag{2}$$

正则化方法。Li 等 [3] 提出 FedProx，在本地目标中添加近端项约束局部模型与全局模型的偏离：

$$\min_{w} F_k(w) + \frac{\mu}{2} \|w - w^{(t)}\|^2, \tag{3}$$

其中 $\mu > 0$ 控制个性化程度。当 $\mu \to 0$ 时退化为纯本地训练；当 $\mu \to \infty$ 时退化为 FedAvg。

元学习方法。Jiang 等将模型无关元学习 (MAML) 引入联邦学习，使全局模型具备良好的本地适应能力。目标函数为：

$$\min_{w} \sum_{k=1}^{K} \frac{n_k}{n} F_k\big(w - \alpha \nabla F_k(w)\big), \tag{4}$$

其中 α 为本地自适应步长。然而，元学习需要多步梯度回传，显著增加了边缘设备的计算负担。

原型学习。Tan 等 [8] 提出 FedProto，通过交换类别原型而非完整模型参数实现个性化：

$$\mathcal{L}_k = \mathcal{L}_{\text{cls}} + \lambda \sum_{c} \|p_{k,c} - p_{g,c}\|^2, \tag{5}$$

其中 $p_{k,c}$ 与 $p_{g,c}$ 分别为客户端 k 与全局原型。该方法通信量小，但原型对数据分布偏移敏感，且缺乏严格的收敛保证。

2.3 聚类与分组策略

聚类方法假设客户端可被划分为若干个同质子组，组内数据分布近似 IID。Sattler 等 [7] 提出基于模型参数余弦相似度的分层聚类，将相似客户端归为一簇：

$$sim(w_i, w_j) = \frac{\langle w_i, w_j \rangle}{\|w_i\| \|w_j\|}, \quad \mathcal{C} = \text{Cluster}(\{w_k\}). \tag{6}$$

各簇内独立执行 FedAvg，获得簇级模型。然而，聚类需要额外计算相似度矩阵，$O(K^2)$ 复杂度在边缘节点动态加入退出时难以维护。

另一种思路是**多任务学习**。Smith 等将联邦学习视为共享表示下的多任务优化问题，引入 MOCHA 算法，利用对偶坐标上升求解。但其依赖于强凸假设，对深度神经网络难以直接适用。

2.4 知识蒸馏与迁移学习

知识蒸馏 (Knowledge Distillation, KD) 允许客户端与服务器交换软标签或 logits，而非完整模型参数。Lin 等提出 FedDF，各客户端上传本地模型，服务器在公共数据集上通过集成蒸馏构建全局模型：

$$\mathcal{L}_{\text{KD}} = -\sum_{i} \sum_{c} p^{c}_{\text{ens}}(x_i) \log p^{c}_{g}(x_i), \tag{7}$$

其中 $p_{\text{ens}} = \frac{1}{K} \sum_k p_k(x_i)$ 为集成软标签。该方法降低了对称性要求，但边缘场景下公共数据集往往不可得，且服务器侧蒸馏引入了额外的计算开销。

2.5 资源受限边缘环境下的缺陷

上述方法在边缘部署时面临以下共性缺陷：

(1) **计算开销大**。个性化联邦学习与元学习通常需要多轮本地迭代或二阶梯度计算，对仅具备 ARM Cortex-M 系列微控制器的边缘节点而言难以承受。

(2) **通信冗余**。聚类与分组策略需要维护额外的相似度矩阵或簇分配向量，增加了控制平面开销；知识蒸馏虽减少了单次传输量，但迭代蒸馏的轮数往往更多。

(3) **存储需求**。客户端需要同时保存全局模型与本地个性化模型，对内存容量不足 10KB 的传感器节点形成严重挑战。

(4) **超参数敏感**。FedProx 中的 μ、FedProto 中的 λ 等超参数需要根据数据异构程度动态调整，边缘端缺乏足够的验证数据支撑自动调参。

3 激励机制设计的实用困境

边缘节点的理性自私性导致” 搭便车” 与” 虚假汇报” 问题。激励机制旨在通过报酬设计激励高贡献节点参与训练。然而，现有方案面临以下困境：

3.1 信息不对称与贡献度量

准确的贡献度量是激励设计的前提。Shapley 值被广泛视为公平的贡献分配准则，但其计算需要枚举所有可能的客户端子集：

$$\phi_k = \sum_{\mathcal{S}\subseteq\mathcal{K}\setminus\{k\}} \frac{|\mathcal{S}|!(K-|\mathcal{S}|-1)!}{K!}\big[v(\mathcal{S}\cup\{k\}) - v(\mathcal{S})\big], \tag{8}$$

其中 $v(\cdot)$ 为特征函数。$O(2^K)$ 复杂度使其在边缘场景不可行。近似方法如蒙特卡洛采样或截断 Shapley 值虽降低了复杂度，但引入了估计误差，理性客户端可能因报酬不公而退出。

Zhan 等 [9] 提出基于学习的方法，训练一个贡献评估网络替代 Shapley 值。然而，评估网络本身需要大量历史数据训练，在系统冷启动阶段无法部署。

3.2 预算约束与动态环境

Lim 等 [5] 设计了层次化激励合约，服务器根据预算约束与客户端成本分布求解最优报酬：

$$\max_{\{r_k\}} \sum_k U_k(r_k, c_k) \quad \text{s.t.} \quad \sum_k r_k \le B, \tag{9}$$

其中 r_k 为客户端 k 的报酬，c_k 为其成本，B 为总预算。但该模型假设客户端成本分布已知，且为静态博弈。在边缘环境中，设备电量、信道质量与可用带宽时变，静态合约无法适应动态约束。

3.3 隐私与可验证性矛盾

激励机制要求客户端上报本地信息（如数据量、计算成本），但这与隐私保护目标冲突。区块链辅助的联邦学习试图通过智能合约实现透明支付，但共识机制（如 PoW、PoS）在边缘设备上开销巨大，违背了联邦学习降低通信成本的初衷。

4 折中可行框架：轻量级启发式与数据保护

鉴于上述方法在边缘场景下的部署困境，本文提出一个结合**简单启发式客户端选择**与**轻量级数据保护**的折中框架，命名为 Lite-EdgeFed。其核心思想是：在有限资源下，与其追求复杂的算法最优性，不如通过合理的客户端筛选与轻量级聚合提升系统的实用鲁棒性。

4.1 框架设计

阶段一：启发式客户端选择。服务器在每一轮通信中，基于客户端历史响应延迟与本地损失下降速率进行简单筛选。定义客户端 k 的效用分数：

$$s_k^{(t)} = \alpha \cdot \frac{\Delta L_k^{(t)}}{\Delta L_{\max}^{(t)}} + (1-\alpha) \cdot \frac{\tau_{\max} - \tau_k^{(t)}}{\tau_{\max}}, \tag{10}$$

其中 $\Delta L_k^{(t)} = L_k^{(t-1)} - L_k^{(t)}$ 为本地损失下降量，$\tau_k^{(t)}$ 为响应延迟，$\alpha \in [0,1]$ 为权衡系数。服务器选择分数最高的 m 个客户端参与本轮聚合。该启发式仅需 $O(K)$ 比较，无需复杂优化求解。

阶段二：轻量级差分隐私聚合。为保护本地数据隐私，在聚合阶段引入高斯机制。客户端在上传模型前添加校准噪声：

$$\tilde{w}_k = w_k + \mathcal{N}(0, \sigma^2 S^2 \mathbf{I}), \tag{11}$$

其中 S 为模型更新的敏感度，σ 为噪声乘子。根据差分隐私的平行组合性质，若每个客户端满足 (ε, δ)-DP，则整体聚合输出满足相同的隐私保证。为降低噪声对模型精度的影响，服务器采用加权平均：

$$w^{(t+1)} = \sum_{k \in \mathcal{S}_t} \frac{n_k}{\sum_{j \in \mathcal{S}_t} n_j} \tilde{w}_k^{(t)}. \tag{12}$$

阶段三：自适应早停。考虑到边缘节点电量有限，引入基于验证损失的自适应早停：若连续 E 轮全局验证损失未下降，则触发终止，避免无效训练。

4.2 复杂度与可行性分析

Lite-EdgeFed 的每轮通信复杂度为 $O(m{\cdot}d)$,d 为模型维度;计算复杂度为 $O(K \log K + m \cdot d)$，主要来自排序与加权平均。与 SCAFFOLD[2] 需要额外传输控制变量 ($O(d)$ 翻倍) 相比，Lite-EdgeFed 仅增加 $O(K)$ 的分数计算。与基于 Shapley 值的激励方案相比，启发式选择避免了指数级复杂度。

在数据保护层面，轻量级高斯机制无需同态加密或安全多方通信 (SMPC) 的繁重密码学操作，适合计算能力受限的边缘设备。当然，其隐私-效用权衡不如完全同态加密方案严格，但在工程实践中，$\varepsilon \leq 3$ 的差分隐私已能提供足够的经验保护。

5 全局模型与局部个性化模型的讨论

近年来，随着 PFL 研究的深入，部分学者主张" 放弃全局模型，全面转向局部个性化模型"。本文认为，这一观点在边缘联邦学习场景下过于激进，应辩证看待。

5.1 支持局部个性化的论据

从统计学习理论角度，全局模型的期望风险可分解为：

$$\mathbb{E}[R(\hat{w})] - R^* = \underbrace{\mathbb{E}[R(\hat{w}) - R(\bar{w})]}_{\text{估计误差}} + \underbrace{R(\bar{w}) - R(w^*)}_{\text{近似误差}} + \underbrace{R(w^*) - R^*}_{\text{不可约误差}}, \tag{13}$$

其中 $\bar{w}$ 为经验风险极小点，w^* 为总体最优。当数据 Non-IID 程度加剧时，全局最优 w^* 与局部最优 w_k^* 的偏差增大，近似误差项显著上升，此时全局模型的泛化性能下降。个性化模型通过为每个客户端拟合局部最优，有效降低近似误差。

此外，从公平性角度看，全局模型可能损害少数群体（数据量小的客户端）的利益，而个性化模型保证每个客户端获得适合自身的模型。

5.2 支持保留全局模型的论据

然而，完全放弃全局模型在边缘场景存在以下问题：

(1) **收敛性保证**。全局目标式 (1) 是凸组合（或非负加权组合），在凸设定下具有良好的收敛性。而个性化模型将系统解耦为 K 个独立优化问题，失去了联邦学习的协同增益。Li 等 [4] 证明，在适当的 Non-IID 度量 $\Gamma = \sum_k \frac{n_k}{n} \|\nabla F_k(w^*)\|^2$ 下，FedAvg 以 $O(1/\sqrt{T})$ 速率收敛至全局最优邻域。若无全局模型作为锚点，个性化模型可能过拟合本地小样本。

(2) **冷启动与迁移**。新加入的客户端在纯个性化框架下无历史模型可用，必须从零训练。而全局模型可作为预训练权重，显著加速新客户端的收敛。

(3) **部署与维护成本**。在边缘环境中，管理 K 个不同的个性化模型需要 K 倍的存储与版本控制开销。相比之下，维护一个全局模型配合少量本地微调参数，更符合资源受限的现实。

(4) **知识共享**。全局模型起到了知识蒸馏与特征表示共享的作用。实验表明，即使数据高度 Non-IID，底层卷积特征仍具有跨域迁移能力 [1]。切断全局共享将导致" 信息孤岛"。

5.3 本文观点

本文认为，边缘联邦学习应采取" **弱全局模型 + 轻量个性化**" 的混合策略。具体而言：

- 在训练阶段保留全局模型作为知识汇聚的锚点，但允许适度的本地偏差（如 FedProx 中的近端项）。- 在推理阶段，允许客户端基于本地少量数据对全局模型进行 1-2 轮梯度微调，实现快速个性化。- 对于资源极度受限的节点，直接采用全局模型，放弃个性化；对于资源充裕的节点，启用更深的个性化层。

这种分层策略兼顾了统计异构性的缓解与系统复杂度的控制，是当前边缘环境下最务实的选择。

6 结论

本文系统综述了边缘联邦学习中的统计异构性与激励机制两大挑战。现有方法（个性化 FL、聚类、知识蒸馏）在理论上取得了显著进展，但在资源受限的边缘环境下普遍存在计算、通信与存储开销过大的缺陷。激励机制设计则面临信息不对称、预算约束与隐私可验证性矛盾的困境。基于此，本文提出 Lite-EdgeFed 折中框架，通过启发式客户端选择、轻量级差分隐私聚合与自适应早停，在简单性与有效性之间取得平衡。关于全局模型与局部个性化模型的争论，本文主张保留弱全局模型作为知识共享锚点，辅以轻量本地微调的混合策略，而非全面转向纯个性化。未来工作将探索基于强化学习的动态 α 调度，以进一步优化式 (10) 中的权衡系数。

参考文献

[1] M. G. Arivazhagan, Varun Aggarwal, Anit Kumar Singh, and Sunav Choudhary. Federated learning with personalization layers. *arXiv preprint arXiv:1912.00818*, 2019.

[2] Sai Praneeth Karimireddy, Satyen Kale, Mehryar Mohri, Sashank Reddi, Sebastian Stich, and Ananda Theertha Suresh. SCAFFOLD: Stochastic controlled averaging for federated learning. In *International Conference on Machine Learning (ICML)*, pages 5132–5143. PMLR, 2020.

[3] Tian Li, Anit Kumar Sahu, Manzil Zaheer, Maziar Sanjabi, Ameet Talwalkar, and Virginia Smith. Federated optimization in heterogeneous networks. *Proceedings of Machine Learning and Systems*, 2:429–450, 2020.

[4] Xiang Li, Kaixuan Huang, Wenhao Yang, Shusen Wang, and Zhihua Zhang. On the convergence of fedavg on non-iid data. In *International Conference on Learning Representations (ICLR)*, 2020.

[5] Wei Yang Bryan Lim, Nguyen Cong Luong, Dinh Thai Hoang, Ying Jiao, Yutao Jia, Ying-Chang Liang, Qiang Yang, Dusit Niyato, and Chunyan Miao. Federated learning in mobile edge networks: A comprehensive survey. *IEEE Communications Surveys & Tutorials*, 22(3):2031–2061, 2020.

[6] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Aguera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 1273–1282. PMLR, 2017.

[7] Felix Sattler, Simon Wiedemann, Klaus-Robert Müller, and Wojciech Samek. Robust and communication-efficient federated learning from non-iid data. *IEEE Transactions on Neural Networks and Learning Systems*, 31(9):3400–3413, 2019.

[8] Alysa Ziying Tan, Han Yu, Lizhen Cui, and Qiang Yang. Fedproto: Federated prototype learning over heterogeneous devices. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 8449–8457, 2022.

[9] Yue Zhan, Peng Li, Song Guo, Zicong Huo, and Boqing Gong. A learning-based incentive mechanism for federated learning. *IEEE Internet of Things Journal*, 7(7):6360–6368, 2020.